


Prédiction de l'énergie moléculaire

sous contraintes de symétrie physique

Maël Montillet · Victor Lin

Matrice de Coulomb enrichie & DimeNet++



Une régression sous contrainte de symétrie

- Apprendre un modèle unique $E(r)$, valable pour toutes les molécules, à partir de la géométrie 3D et du type des atomes → régression en grande dimension.
- Difficulté centrale : l'énergie ne change pas si on translate, tourne ou renumérote les atomes.
- Métrique du challenge : erreur absolue moyenne (MAE).

Translation

T_b

Rotation


T_U

Permutation

T_σ

$$E(T_b \mathbf{r}) = E(T_U \mathbf{r}) = E(T_\sigma \mathbf{r}) = E(\mathbf{r})$$

Figure 1 — coordonnées cartésiennes sans liaisons | id_9 | $E=-68.509$



Traduire, tourner ou renuméroter les atomes laisse E inchangée (id=9).

L'énergie est avant tout extensive



- 3 306 molécules d'entraînement · 826 de test (sous-ensemble QM7-X).
- 6 éléments : H et C majoritaires (~91 %) ; N, O ; S et Cl très rares (1 seul Cl en train).
- Énergies de -103 à -19 (moy. -70,6 ; écart-type 10,3).

-0,96

corrélation énergie ↔ nombre d'atomes
(Pearson)

Lecture pour la modélisation

Capturer d'abord la composition
(combien d'atomes, de quel type), puis
raffiner avec la géométrie.




Distribution des énergies ; relation quasi affine énergie / taille → énergie extensive.

Matrice de Coulomb enrichie

- Molécule de taille variable → vecteur de taille fixe : Coulomb triée + padding (276), puis enrichie de descripteurs chimiques (309).
- Descripteurs ajoutés (notre apport) : composition, statistiques de distances, rayons covalents / liaisons, électronégativité.
- Invariances : translation et rotation exactes ; permutation obtenue en triant les lignes par norme.
- Régression par ExtraTrees (scikit-learn), évaluée en validation croisée 5 plis.

Résultat : **MAE 0,130** (0,164 sans enrichissement · OOF 0,129)




Matrice de Coulomb triée : atomes lourds en haut à gauche.

DimeNet++ : un GNN qui voit les angles

- Molécule = graphe : atomes = nœuds, arêtes entre atomes plus proches qu'un cutoff (5 Å).
- Un GNN est invariant par permutation par construction.
- Apport de DimeNet : des messages directionnels qui utilisent distances ET angles entre arêtes.
- Justifié par la physique : $E = E_{\text{liaison}} + E_{\text{angle}} + E_{\text{torsion}} + E_{\text{non-liées}}$.
- Distances et angles invariants par rotation/translation ; sortie = somme sur les atomes $\rightarrow$ invariante.

Progression : **DimeNet 0,0301** $\rightarrow$ **DimeNet++ 0,0222**



Mise à jour du message m_{ji} à partir des voisins et des angles (papier DimeNet).

Delta learning + validation croisée 5 plis

1 Delta learning


Le réseau n'apprend que le résidu d'une baseline linéaire sur la composition ($R^2 = 0,997$). Cible normalisée → entraînement plus stable.

2 Validation croisée 5 plis

5-fold stratifié (graine 42) : OOF non biaisé, tout le train exploité. Gradients bornés ($\text{max_grad_norm} = 10$).


3 Échantillonnage pondéré

On sur-échantillonne les molécules à fort résidu : conformations atypiques et éléments rares (S, Cl).



Courbes train / validation par pli (échelle log) — le point noir marque le meilleur checkpoint.

MAE 0,0151 sur le test caché



Parité OOF : prédictions alignées sur la diagonale.

0,0157 Ha

MAE sur le test caché — moyenne des 5 modèles (meilleur score)

0,0205

MAE OOF (5 plis) · $R^2 = 0,99995$

$\approx 10\times$

plus précis que la baseline Coulomb (0,13)

Limite : erreurs concentrées sur S et Cl — exemple : grosse erreur sur (id=821) (seule avec S + Cl).

Composition d'abord, géométrie ensuite

CE QU'ON RETIENT

- Deux pipelines invariants par translation, rotation et permutation.
- Baseline Coulomb enrichie : MAE 0,13 — simple, interprétable, reproductible.
- DimeNet++ (distances + angles) + delta learning + 5 plis : MAE 0,0151, notre meilleur résultat.

LIMITES & PISTES

- Mauvaise généralisation sur S et CI (très sous-représentés).
- Détection hors-distribution + loss pénalisant davantage les éléments rares.
- Réglage systématique des hyperparamètres (grid search / Bayésien avec optuna).

Merci ! — questions ?

Annexes



Slides de support pour la phase de questions



Composition & distribution du jeu de données

Élément	Train	%	Test	%
H	30 745	60,99	7 707	61,19
C	15 294	30,34	3 778	30,00
N	2 332	4,63	607	4,82
O	2 018	4,00	500	3,97
S	18	0,036	1	0,008
Cl	1	0,002	2	0,016

Proportions train / test concordantes. Le chlore (1 atome en train) et le soufre (18) sont des cas extrêmes → difficultés de généralisation.




Composition train/test · distribution du nombre d'atomes (5 à 23, moy. 15,2).

Coulomb : représentation & invariances

$$M_{ij} = \frac{1}{2} Z_i^{2,4} \quad (i = j) \quad Z_i Z_j / \|R_i - R_j\| \quad (i \neq j)$$

- Diagonale → type d'atome (Z) ; hors-diagonale → types + géométrie (distances).
- Pipeline : tri des lignes/colonnes par norme ↓, padding jusqu'à MAX_ATOMS = 23, vectorisation du triangle supérieur → 276 composantes.
- + descripteurs physico-chimiques → 309 composantes.
- Vérification empirique : translation, rotation (z), permutation aléatoire → vecteur identique à la précision machine.

Composant	Invariances
Matrice de Coulomb	Translation, rotation ; permutation après tri
Padding + triangle sup.	Conserve les invariances
Composition atomique	Translation, rotation, permutation
Stats de distances	Translation, rotation, permutation
Rayons / liaisons approx.	Invariant (distances, comptages)



Enrichissement : descripteurs physico-chimiques (309)

1

Composition

Nombre total d'atomes, somme et statistiques des numéros atomiques, comptage par type. Capture directement l'extensivité.

2

Géométrie globale

Statistiques (min, moyenne, écart-type, médiane, max) sur l'ensemble des distances interatomiques.

3

Chimie approximative



Liaisons potentielles via rayons covalents (seuil 1,25) + statistiques d'électronégativité de Pauling.

Toutes ces features préservent les invariances : elles ne reposent que sur des comptages, distances ou statistiques symétriques — jamais sur les coordonnées brutes ni sur l'ordre des atomes. Notre apport n'est pas un nouveau modèle mais une baseline Coulomb enrichie, défendable et reproductible.

Comparaison de modèles & réglage (CV 5 plis)




Modèle	MAE train	MAE validation
Extra Trees enrichi	≈ 0	0,130 ± 0,011
Extra Trees Coulomb	≈ 0	0,164 ± 0,010
Ridge Coulomb	1,11	1,212 ± 0,008
Kernel Ridge RBF Coulomb	4,39	7,344 ± 0,767
Dummy (médiane)	7,49	7,486 ± 0,180

Meilleure config : n_estimators = 500, max_features = 1,0, min_samples_leaf = 1 → MAE 0,1293 ± 0,0108. Les arbres dominent ; modèles linéaires et à noyau insuffisants.



Comparaison train/validation · robustesse au réglage des hyperparamètres.

Analyse des erreurs out-of-fold & soumission



MAE OOF = 0,129 $\approx$ 1,3 % de l'écart-type des énergies. L'erreur décroît avec la taille : grandes molécules (≥ 14 atomes) très bien prédites ; les rares petites (5–10) concentrent les pires cas (jusqu'à ~ 14 sur une molécule de 5 atomes). Distribution des erreurs fortement piquée en zéro. Soumission Kaggle : distributions test/train superposées, sans valeur hors domaine.

Parité OOF (gauche) · erreur vs taille et distribution (droite).

Message passing & architecture

$$h_i^{(l+1)} = \sum_{j \in N(i)} m_{ji}^{(l+1)}$$

$$m_{ji}^{(l+1)} = f_{\text{update}}(m_{ji}, \sum f_{\text{int}}(m_{kj}, e_{\text{RBF}}, a_{\text{SBF}}))$$

- e_{RBF} = distance i-j en base radiale ; a_{SBF} = distance + angle (k,j,i) en base sphérique.
- Embeddings h initialisés par numéro atomique (appris).
- Sortie : $t = \sum_i \sum_l t_i$ (somme sur atomes et couches).

Embedding block

Associe à chaque atome son embedding (Z) + 1^{re} mise à jour avec les distances voisines.


Interaction block

Implémente le message passing (f_{update} , f_{int}) via des réseaux de neurones.

Output block

Transforme chaque embedding en contribution t_i de la couche.

Pourquoi DimeNet est invariant



Référence : l'arête ji pour calculer les angles.

- Les distances entre atomes sont invariantes par rotation et translation.
- Le schéma d'agrégation (angles + distances) tourne avec la molécule → couches d'interaction équivariantes par rotation (idem translation).
- L'embedding n'utilise que Z et les distances → également équivariant.
- La prédiction finale somme les contributions de chaque atome : agréger une représentation équivariante par somme donne un résultat invariant par rotation et translation.
- Le GNN est invariant par permutation par construction.

Progression des expériences

Étape	Changement clé	Score MAE
DimeNet	baseline angulaire	0,0301
DimeNet++	couches + embeddings optimisés	0,0222
+ delta learning	résidu d'une baseline linéaire	0,0251
Modèle final (5-fold)	moyenne des 5 modèles	0,0151

Tentatives non retenues

Embeddings initiaux informés par la physique
(couches s/p/d, conductivité...) pour les atomes rares
→ pas d'amélioration.

AdamW + Cosine Annealing WR
→ mauvaise combinaison avec la moyenne mobile exponentielle (EMA).

Setup : code DimeNet officiel (TensorFlow 2.10.1, GPU), optimiseur Adam + EMA, loss MAE, learning rate avec warmup linéaire puis décroissance exponentielle. Cutoff et architecture par défaut sauf mention.

Delta learning : apprentissage du résidu

$$E_{\text{lin}}(n) = w^T n + b \quad R^2 = 0,997$$

$$r = E - E_{\text{lin}}(n)$$

$$y = (r - \mu_r) / \sigma_r$$

$$\hat{E} = E_{\text{lin}}(n) + \sigma_r \hat{y} + \mu_r$$

- L'énergie est extensive → une régression linéaire sur la composition n explique déjà l'essentiel.
- DimeNet++ n'apprend que le résidu normalisé y ; on reconstruit $\hat{E}$ à l'inférence.
- Classe `LREnergyScaler` (fit / transform / inverse_transform).
- Intérêt : le réseau ne réapprend plus la dépendance triviale à la taille ; cible homogénéisée → entraînement plus stable et plus précis.

Modèle final : améliorations & hyperparamètres


- `max_grad_norm = 10` : gradients bornés (avant : 10^3 , soit non bornés) → entraînement plus stable.
- 5-fold stratifié (MultilabelStratifiedKFold, graine 42) : $\approx 2\,645$ train / 661 val par pli ; OOF non biaisé.
- Échantillonnage du DataProvider $\propto$ résidu absolu $|E - \hat{E}_{LR}| \rightarrow$ plus d'exemples difficiles (S, CI).

Baseline LR : $R^2 = 0,997$, résidu std $\approx 0,56$ Ha.

Paramètre	Valeur
dropout_rate	0,1
learning_rate	10^{-3} (warmup 3% + déc. exp.)
decay_rate	0,01
batch_size	16
max_grad_norm	10
epochs / patience	500 / 60 époques

Configuration basée sur les époques, avec arrêt anticipé (patience) sur la loss de validation.


Courbes d'entraînement par pli



- Hétérogénéité entre plis : meilleure MAE val de 0,029 (fold 2) à 0,046 (fold 0).
- Arrêt anticipé : le fold 4 s'arrête le plus tôt (~310 époques) ; folds 0 et 2 utilisent presque les 500.
- Léger sur-apprentissage : MAE train finit sous la MAE val ; dropout (0,1) + arrêt anticipé le limitent.

Résultats out-of-fold (3 306 molécules)

Métrique	Valeur
MAE globale (OOF)	0,0205 Ha
Médiane	0,0104 Ha
90 ^e percentile	0,0408 Ha
RMSE	0,0756 Ha
R ²	0,999946
r (Pearson)	0,99997
Moyenne MAE/pli	0,0205 ± 0,0031



Erreur ↑ avec la taille (MAE relative ~constante → extensif) · S/Cl pires · id=821 (S+Cl) = 3,42 Ha.

Résultat sur le jeu de test

Soumission	Test visible	Test caché
Moyenne des 5 modèles	0,0150	0,0167
Moyenne pondérée (par MAE val)	0,0151	0,0157

- La moyenne non pondérée, jugée plus fiable, a été choisie comme prédiction finale.
- Les deux restent nos deux meilleures méthodes ($\approx 0,015$ sur le test caché).
- Soit presque un ordre de grandeur sous la baseline Coulomb ($MAE \approx 0,13$).

0,0157 Ha

meilleur score (caché)